


PINKFAIRNESS

GUÍA DE PROCESO DE DATA MINING CON ENFOQUE DE EQUITAD

El presente documento tiene como propósito ofrecer una guía práctica para llevar a cabo un proceso de Machine Learning (ML) con un enfoque en la equidad. La guía se basa en un enfoque estructurado, compuesto por fases y tareas definidas, complementado con un conjunto de herramientas diseñadas específicamente para explorar datos en busca de sesgos y desarrollar modelos que promuevan la equidad (Fahse, Huber, & van Giffen, 2021).

La figura 1, ilustra el conjunto de fases que estructura modularmente el Framework, estas fases avanzan de manera secuencial. Inicialmente, se establecen las razones que motivan la construcción del modelo. Luego, se procede a comprender los datos que serán utilizados y, posteriormente, a prepararlos para el entrenamiento. En las fases de modelado, evaluación e intervenciones de equidad, se genera un ciclo en el que los modelos son entrenados con diferentes tipos de intervención y evaluados para determinar su efectividad. Según las consideraciones del proyecto y la mejora con respecto a la línea base, el usuario puede optar por reprocesar los datos con enfoques alternativos y repetir el proceso de entrenamiento, evaluación e intervención de equidad para obtener mejores resultados.

Figura 1. Fases que conforman el framework



1. Motivación

El sistema se orienta a automatizar la asignación del Beneficio de Inserción Económica (BIE) para personas desmovilizadas que participan en la ruta de reintegración promovida por la Agencia para la Reincorporación y la Normalización (ARN) en Colombia. La población objetivo está compuesta por excombatientes en proceso de reincorporación a la vida civil. Su objetivo es agilizar y transparentar la entrega del capital semilla que les permite iniciar o fortalecer un proyecto productivo, garantizando al mismo tiempo que el proceso sea justo y se respeten los datos.

Tabla 1. Requisitos generales

Requisito	Descripción
Población objetivo	La población objetivo está conformada por personas desmovilizadas que han ingresado al proceso de reintegración liderado por la ARN. Son exintegrantes de grupos armados ilegales en proceso de reincorporación a la vida civil. Las mujeres están menos representada en el conjunto de datos, lo que exige prestar atención a la equidad de género.
Contexto	El sistema tiene como propósito asignar automáticamente el BIE a quienes cumplieron su ruta de reintegración. Para ello se construirá un modelo de clasificación binaria que predice si un individuo debe recibir o no el beneficio. El alcance de la solución es nacional.
Datos sensibles	El único atributo sensible identificado es SEXO_ENC, que indica el sexo al nacer. El manejo de los datos cumple con la normativa colombiana de protección de datos (Ley 1581 de 2012, Ley 1266 de 2008 y Decreto 2573 de 2015); los datos fueron anonimizados y puestos al público en general.
Limitaciones	Cobertura heterogénea: algunos departamentos, como Antioquia, están sobrerrepresentados. La fuente es histórica y proviene de registros autodeclarados o recolectados por terceros, por lo que pueden existir inconsistencias. El modelo es binario; no contempla niveles intermedios de beneficio ni recomendaciones alternativas.
Beneficios	Agiliza la toma de decisiones, aumenta la transparencia y trazabilidad, prioriza de forma justa a quienes cumplieron el proceso y contribuye a la sostenibilidad económica y social de los excombatientes.
Implicaciones éticas	Una respuesta correcta permite focalizar los recursos y reducir la vulnerabilidad de los beneficiarios; una salida errónea podría negar el beneficio a quien lo merece o asignarlo a quien no lo necesita, con consecuencias económicas y sociales para personas que han vivido conflicto armado.
Mantenimiento	Se recomienda monitorear trimestral o semestralmente el desempeño y la equidad del modelo. Se dará especial seguimiento al recall (evitar falsos negativos), al f1 score (equilibrio entre precisión y recall) y a la diferencia en las tasas de falsos negativos entre grupos. Un valor elevado de f1 y un false negative rate difference cercano a 0 indican un modelo robusto y equitativo.

2. Comprensión de los datos

Implica un análisis de los datos disponibles para la construcción del modelo. Este paso ayuda a prevenir inconvenientes imprevistos durante la siguiente etapa (Chapman, et al., 2000) (Saltz & Hotz, 2020).

2.1 Recopilación de datos iniciales

Los datos fueron obtenidos del portal de datos abiertos de la ARN. El conjunto incluye registros de todos los desmovilizados que ingresaron al proceso de reintegración entre 2002 y 2018. El dataset contiene 21368 registros y 40 atributos de entrada. No se observaron valores nulos ni atributos de varianza cero.

Tabla 2. Descripción general del dataset

Ítem	Descripción
Fuente de Datos	Datos abiertos de la Agencia para la Reincorporación y la Normalización (ARN) de Colombia.
Filas	21368 registros combinando las particiones de entrenamiento y prueba.
Columnas	40 atributos de entrada y una columna de salida (DES_BIE_ENC).
Atributos sensibles	SEXO_ENC (0 = mujer, 1 = hombre). Las mujeres se consideran el grupo privilegiado y los hombres el grupo no privilegiado
Atributo de clase	DES_BIE_ENC (1 = recibe el BIE, 0 = no recibe)
Formato	Tablas CSV con variables numéricas codificadas
Descripción	Contiene información sociodemográfica (edad, sexo, ubicación), ruta de reintegración, beneficios recibidos, información censal familiar, ocupación y acciones de servicio social. Los datos abarcan ingresos al proceso entre 2002 y 2018 y fueron liberados en el portal de datos abiertos de Colombia.

2.2 Descripción de los datos

En esta sección se busca comprender la naturaleza y las características de cada atributo en el conjunto de datos. Esto implica examinar el tipo de dato, la escala de medición, el rango de valores posibles, la presencia de valores atípicos o perdidos, y cualquier otra información relevante relacionada con cada atributo (Holland, Hosny, Newman, Joseph, & Chmielinski, 2018) (Piorkowski, Richards, & Hind, 2022) (Martínez-Plumed, et al., 2021).

Tabla 3. Descripción de atributos

Atributo	Descripción
POS_CON_ENC	Define si el individuo tiene registrado como integrante de su grupo familiar Cónyuge o Compañero/a permanente según la aplicación del censo de familia
BEN_TRV_ENC	Indica si recibió atención psicosocial, con el fin de desarrollar y fortalecer competencias en su vida familiar, educativa, productiva y comunitaria, y guiar sus esfuerzos hacia la solución de necesidades y problemas específicos
BEN_FA_ENC	Define si el individuo recibió beneficio en Formación Académica en el año anterior
BEN_FPT_ENC	Define si el individuo recibió beneficio en Formación Para el Trabajo en el año anterior
BEN_PDT_ENC	Define si el individuo recibió beneficio en Plan de trabajo en el año anterior
POS_SPU_ENC	Identifica los individuos que en la Encuesta de Vivienda reportaron tener servicios públicos de agua, alcantarillado y luz
REG_SAL_ENC	Variable calculada que permite establecer el régimen de salud del individuo teniendo en cuenta tanto la información del RUAF como de PILA
SEXO_ENC	Indica el sexo de la persona al nacer

NIV_EDU_ENC	Máximo ciclo de formación aprobado por el individuo Alfabetización, Básica Primaria, Básica Secundaria, Bachiller
POS_SSO_ENC	Proporciona el estado del individuo a la fecha de corte acerca de su vinculación a Acciones de Servicio Social
GRUPO_ETAR_ENC_Entre 18 y 25 años	Rango de edad al que pertenece el individuo según su fecha de nacimiento 18 y 25 años
GRUPO_ETAR_ENC_Entre 26 y 40 años	Rango de edad al que pertenece el individuo según su fecha de nacimiento 26 y 40 años
GRUPO_ETAR_ENC_Entre 41 y 60 años	Rango de edad al que pertenece el individuo según su fecha de nacimiento 41 y 60 años
GRUPO_ETAR_ENC_Mayor de 60 años	Rango de edad al que pertenece el individuo según su fecha de nacimiento Mayor de 60 años
EX_GRUPO_ENC_AUC	Grupo del cual era miembro el individuo antes de su desmovilización Autodefensas Unidas de Colombia
EX_GRUPO_ENC_ELN	Grupo del cual era miembro el individuo antes de su desmovilización Ejército de Liberación Nacional
EX_GRUPO_ENC_EPL	Grupo del cual era miembro el individuo antes de su desmovilización Ejército Popular de Liberación
EX_GRUPO_ENC_ERG	Grupo del cual era miembro el individuo antes de su desmovilización Ejército Revolucionario Guevarista
EX_GRUPO_ENC_ERP	Grupo del cual era miembro el individuo antes de su desmovilización Ejército Revolucionario del Pueblo
EX_GRUPO_ENC_FARC	Grupo del cual era miembro el individuo antes de su desmovilización Fuerzas Armadas Revolucionarias de Colombia
TIP_VIV_ENC_Apartamento	Indica si la persona vive en Apartamento
TIP_VIV_ENC_Casa	Indica si la persona vive en Casa
TIP_VIV_ENC_Casa_Lote	Indica si la persona vive en Casa Lote
TIP_VIV_ENC_Finca	Indica si la persona vive en Finca
TIP_VIV_ENC_Habitacion	Indica si la persona vive en Habitación
TIP_VIV_ENC_Otro	Indica si la persona vive en Otro
TIP_VIV_ENC_Rancho	Indica si la persona vive en Rancho
TIP_VIV_ENC_Vivienda indigena	Indica si la persona vive en comunidad indígena
REG_VIV_ENC_Familiar	Como es el tipo de posesión que tiene sobre la vivienda Familiar
REG_VIV_ENC_No_Registra	Como es el tipo de posesión que tiene sobre la vivienda No Registra
REG_VIV_ENC_Otra_forma	Como es el tipo de posesión que tiene sobre la vivienda Otra forma
REG_VIV_ENC_Sana_posesión_título	Como es el tipo de posesión que tiene sobre la vivienda Sana posesión título
REG_VIV_ENC_arriendo_subarriendo	Como es el tipo de posesión que tiene sobre la vivienda arriendo subarriendo
REG_VIV_ENC_usufructo	Como es el tipo de posesión que tiene sobre la vivienda usufructo
OCU_ECO_ENC_Desocupados	Permite establecer la ocupación económica de los individuos para la fecha de corte Desocupados
OCU_ECO_ENC_Ocupados_Informal	Permite establecer la ocupación económica de los individuos para la fecha de corte Ocupados Informal
DEP_RES_ENC	Departamento donde reside
MUN_RES_ENC	Municipio donde reside

NUM_HIJOS_NOR	Número de hijos y/o hijastros registrados como integrantes del grupo familiar del individuo según la aplicación del censo de familia
AÑO_ING_NOR	Año en que ingreso al proceso de reinserción

Como se muestra en las siguientes tablas, no se identificaron valores nulos, el dataset no contiene valores faltantes ni atributos de varianza cero, no requiere imputación ni por lo tanto a este punto la integridad de los datos se mantiene.

Tabla 4. Estadística atributos ordinales y nominales

Atributo	Tipo	Cantidad	Valores únicos	Más frecuente	Menos frecuente	% nulos
POS_CON_ENC	category	21368	2	1	0	0
BEN_TRV_ENC	category	21368	2	0	1	0
BEN_FA_ENC	category	21368	2	0	1	0
BEN_FPT_ENC	category	21368	2	0	1	0
BEN_PDT_ENC	category	21368	2	0	1	0
POS_SPU_ENC	category	21368	2	1	0	0
REG_SAL_ENC	category	21368	2	1	0	0
SEXO_ENC	category	21368	2	1	0	0
NIV_EDU_ENC	category	21368	4	4	1	0
POS_SSO_ENC	category	21368	3	3	2	0
GRUPO_ETAR_ENC_Entre 18 y 25 años	category	21368	2	0	1	0
GRUPO_ETAR_ENC_Entre 26 y 40 años	category	21368	2	0	1	0
GRUPO_ETAR_ENC_Entre 41 y 60 años	category	21368	2	1	0	0
GRUPO_ETAR_ENC_Mayor de 60 años	category	21368	2	0	1	0
EX_GRUPO_ENC_AUC	category	21368	2	1	0	0
EX_GRUPO_ENC_ELN	category	21368	2	0	1	0
EX_GRUPO_ENC_EPL	category	21368	2	0	1	0
EX_GRUPO_ENC_ERG	category	21368	2	0	1	0
EX_GRUPO_ENC_ERP	category	21368	2	0	1	0
EX_GRUPO_ENC_FARC	category	21368	2	0	1	0
TIP_VIV_ENC_Apartamento	category	21368	2	0	1	0
TIP_VIV_ENC_Casa	category	21368	2	1	0	0
TIP_VIV_ENC_Casa_Lote	category	21368	2	0	1	0
TIP_VIV_ENC_Finca	category	21368	2	0	1	0
TIP_VIV_ENC_Habitacion	category	21368	2	0	1	0
TIP_VIV_ENC_Otro	category	21368	2	0	1	0
TIP_VIV_ENC_Rancho	category	21368	2	0	1	0
TIP_VIV_ENC_Vivienda indigena	category	21368	2	0	1	0


REG_VIV_ENC_Familiar	category	21368	2	0	1	0
REG_VIV_ENC_No_Registra	category	21368	2	0	1	0
REG_VIV_ENC_Otra_forma	category	21368	2	0	1	0
REG_VIV_ENC_Sana_posesi ³ n t ³ Atulo	category	21368	2	0	1	0
REG_VIV_ENC_arriendo_subarr iendo	category	21368	2	0	1	0
REG_VIV_ENC_usufructo	category	21368	2	0	1	0
OCU_ECO_ENC_Desocupados	category	21368	2	0	1	0
OCU_ECO_ENC_Ocupados_Inf ormal	category	21368	2	1	0	0
NUM_HIJOS_NOR	category	21368	12	0	10	0
DES_BIE_ENC	category	21368	2	1	0	0

Tabla 5. Estadística atributos continuos y discretos

Atributo	Tipo	Cantid ad	Minim o	Mediana	Maximo	Promedi o	Desv Std	% Nulo s	% Cero s
DEP_RES_E NC	float6 4	17094	0.0000 47	0.047220	0.086110	0.021453	0.0296 02	0	0
MUN_RES_E NC	float6 4	17094	0.0000 47	0.008096 22	0.086110 07	0.021429	0.0295 37	0	0
AÑO_ING_N OR	float6 4	17094	2003	2006	2019	2007.402 95	2.9085 45	0	0

La figura 2, muestra la distribución de la variable de clase DES_BIE_ENC. La DES_BIE_ENC = 1 representa aproximadamente el 81 % de los registros, mientras que la clase desfavorable (0) abarca el 19 % restante.

Figura 2. Distribución de las clases



La tabla 6, muestra la distribución de los conjuntos de datos de entrenamiento y pruebas, divididos por clase y atributo sensible. En esta división las clases siguen la misma distribución donde los valores positivos son mayores que los negativos. Adicionalmente, el

sexo masculino tiene la mayor cantidad de beneficios aprobados y rechazados, mientras que las mujeres tienen valores menores.

Tabla 6. Distribución clases y atributos sensibles desmovilizados

Conjunto	S=M C=1	S=M C=0	S=F C=1	S=F C=0
Entrenamiento	11071	2856	2742	425
Pruebas	2787	695	715	77


2.3 Exploración de datos

En esta sección se describen las relaciones entre atributos que reflejan comportamiento de incremento o decremento entre ellas y que guardan alguno tipo de relación en cuanto a la distribución de sus valores, los valores de clase y se segmentan por atributos sensibles, por lo tanto, se visualizaran dos graficas una que refleja la distribución para ese grupo sensible.

En los gráficos que se mostraran, las categorías están ubicadas en el eje x, la altura de la barra indica el número de registros. El contorno sólido corresponde a Clase = 0 y el contorno punteado a Clase = 1. Los colores apilados dentro de la barra describen la distribución de la variable auxiliar (leyenda).


La figura 3, muestra la relación entre, si recibió atención psicosocial, con el fin de desarrollar y fortalecer competencias en su vida familiar, educativa, productiva y comunitaria, y guiar sus esfuerzos hacia la solución de necesidades y problemas específicos (BEN_TRV_ENC) y si el individuo recibió beneficio en plan de trabajo en el año anterior (BEN_PDT_ENC), desagregada por SEXO_ENC, junto con la variable de Clase. En ambos sexos se observa un predominio de BEN_TRV_ENC = 0 y BEN_PDT_ENC = 0, lo que significa que la mayoría de los registros no reportan estos beneficios simultáneamente. Solo una fracción muy pequeña presenta valores de BEN_TRV_ENC = 1, asociada de forma consistente con BEN_PDT_ENC = 1, lo cual sugiere una fuerte dependencia entre ambas variables: cuando se activa un beneficio, tiende a estar presente también el otro. Además, la distribución de la Clase está altamente concentrada en el valor 0, con presencia marginal de Clase = 1, reflejando un desbalance importante. Esto indica que la relación entre los dos beneficios es casi redundante y que se comporta de manera muy similar en ambos sexos, aunque con mayor volumen absoluto en SEXO_ENC = 1.

Figura 3. Relación entre BEN_TRV_ENC y BEN_PDT_ENC



La figura 4, presenta la relación entre los grupos etarios: Entre 26 y 40 años y Entre 41 y 60 años en función de la variable Clase, desagregada por SEXO_ENC. Para SEXO_ENC = 0, se observa que el grupo de 41 a 60 años tiene mayor representación, con predominio de Clase = 0, mientras que en el grupo de 26 a 40 años existe una presencia relevante de Clase = 1, aunque igualmente con predominio de Clase = 0. En cambio, para SEXO_ENC = 1, el grupo de 26 a 40 años es mayoritario, con un número de observaciones en Clase = 1, mientras que el grupo de 41 a 60 años es reducido y se concentra en Clase = 0. Esto sugiere que la relación entre edad y clase varía según el sexo codificado: en el grupo masculino (SEXO_ENC=1) los más jóvenes tienden a aparecer en ambas clases, mientras que en el grupo femenino (SEXO_ENC=0) los mayores están más concentrados en la clase negativa.


Figura 4. Grupos etarios Entre 26 y 40 años y Entre 41 y 60 años



La figura 5, muestra la relación entre los grupos, autodefensas unidad de Colombia (EX_GRUPO_ENC_AUC) y las fuerzas armadas revolucionadas de Colombia (EX_GRUPO_ENC_FARC) diferenciados por SEXO_ENC y la variable de Clase. Para SEXO_ENC = 0 se observan individuos identificados en EX_GRUPO_ENC_FARC = 1, concentrados principalmente en Clase = 1, mientras que los pertenecientes a EX_GRUPO_ENC_AUC = 1 aparecen en menor proporción y con ligera presencia de ambas clases. En contraste, para SEXO_ENC = 1 la mayor concentración se da en EX_GRUPO_ENC_AUC = 1, con predominio de Clase = 0, aunque también existe un volumen en Clase = 1; los registros en EX_GRUPO_ENC_FARC = 1 son menores, pero igualmente se inclinan hacia Clase = 1. En conjunto, la gráfica refleja que la pertenencia a

uno u otro grupo está marcada por diferencias de sexo y que la distribución de clases se concentra en el valor 1, con menor representación de la clase negativa.


Figura 5. Relación entre EX_GRUPO_ENC_AUC y EX_GRUPO_ENC_FARC



En la figura, al separar por SEXO_ENC, se observan patrones distintos entre, si el excombatiente tiene registrado como integrante de su grupo familiar cónyuge o compañero permanente según la aplicación del censo de familia (POS_CON_ENC) y NUM_HIJOS_NOR con la Clase. Para SEXO_ENC=1 (abajo) la mayor concentración de registros está en si POS_CON_ENC=0 y NUM_HIJOS_NOR=0, con clara dominancia de Clase=1; el grupo con POS_CON_ENC=1 es menor, pero muestra mayor dispersión en número de hijos. En cambio, para SEXO_ENC=0 (arriba) la distribución es más equilibrada

entre POS_CON_ENC=0 y 1, y hay presencia de varios niveles de NUM_HIJOS_NOR (especialmente 0–3), con mayor heterogeneidad en la Clase (aparece con más frecuencia Clase=1)

Figura 6.Relación entre POS_CON_ENC y NUM_HIJOS_NOR



En la tabla 7, se muestran las relaciones que se identificaron entre atributos utilizando la visualización de comprensión de los datos y mediante las pruebas numéricas que identifica las relaciones entre todas las variables, cómo estas influyen en la clase que se quiere predecir, y su asociación con el atributo sensible.

Tabla 7. Relación entre atributos

Relación de Atributos		Afirmación
Atributo 1	Atributo 2	
EX_GRUPO_ENC_AUC	SEXO_ENC	El antiguo grupo armado AUC presenta la mayor divergencia entre hombres y mujeres según las distancias de Jensen–Shannon y Kullback–Leibler. La mayoría de las personas que pertenecían a esta organización son hombres, por lo que la variable contiene información sensible sobre el sexo y podría ser un proxi del atributo sensible.
POS_SSO_ENC	DES_BIE_ENC	La participación en acciones de servicio social (POS_SSO_ENC) está altamente relacionada con el beneficio otorgado: los desmovilizados con servicio social activo tienen mayor probabilidad de recibir el BIE.
GRUPO_ETAR_ENC_Entre 26 y 40 años	SEXO_ENC	Los rangos de edad intermedia presentan desviaciones notables en la distribución por sexo. Las mujeres están sobrerrepresentadas en el grupo de 26–40 años, mientras que los hombres predominan en otros rangos. Esto sugiere que la edad y el sexo están asociados; esto sugiere que la edad puede servir como proxi del sexo.

En la tabla 8, se determinan que anomalías fueron identificadas sobre los datos y la propuesta de tratamiento que sugiere realizar.

Tabla 8. Calidad de datos

Atributo	Problema	Intervención	Repercusión
EX_GRUPO_ENC_AUC	Alta correlación con el atributo sensible SEXO_ENC y p-valor significativo en pruebas de relación	Eliminar o agrupar con otros grupos armados para reducir la sensibilidad	Esta variable está fuertemente asociada al sexo masculino; eliminarla reduce ligeramente la proporción de hombres en el conjunto, pero ayuda a evitar que el modelo discrimine por pertenencia

			previa al grupo armado.
GRUPO_ETAR_ENC_*	Asociación con SEXO_ENC y presencia de múltiples categorías	Mantener, pero vigilar su efecto; considerar fusionar rangos extremos	Fusionar rangos de edad muy escasos evita que el modelo ajuste demasiado a grupos minoritarios. Se debe comprobar que esta fusión no cambie la proporción del atributo sensible.

3. Preparación de los datos

En esta etapa los datos deben ser intervenidos con el fin de que tengan las representaciones adecuadas tanto del caso de uso que se está solucionando como el formato que requiere el algoritmo que implementa la tarea que se desea desarrollar (Martínez-Plumed, et al., 2017). Sin embargo, como el alcance del Framework va desde los datos preprocesados, en esta etapa solo se contempla lo relacionado con examinar cómo las características sensibles están relacionadas con otras variables en el conjunto de datos.

3.1 Selección de datos

Para seleccionar las características que alimentan el modelo se eliminaron variables con varianza cero (no se encontraron) y atributos redundantes. Se utilizaron pruebas estadísticas (ANOVA F-test, chi-cuadrado y mutual information) para evaluar la relación entre cada atributo y la clase. Las características con mayor puntuación fueron DEP_RES_ENC, MUN_RES_ENC, NUM_HIJOS_NOR y AÑO_ING_NOR. Sin embargo, dado que algunas de estas variables también presentan divergencias con el sexo, se decidió normalizarlas o discretizarlas y vigilar su impacto durante la modelización.

Además, se examinó la presencia de instancias conflictivas: se encontraron 51 pares de registros con exactamente los mismos valores en las características no sensibles, pero con etiquetas y sexos opuestos. Esto indica la existencia de contradicciones en los datos originales y evidencia la necesidad de controlar los sesgos.

3.2 Limpieza de datos y formateo de datos

Algunos atributos como DEP_RES_ENC, MUN_RES_ENC o NUM_HIJOS_NOR muestran una alta relación con la variable objetivo (otorgamiento del BIE). Aunque esta relación también puede reflejar inequidades estructurales (por ejemplo, diferencias regionales en la oferta de programas), eliminarlos o transformarlos en exceso implicaría perder información del contexto social y económico en el que se toman las decisiones reales. Dichos atributos permiten comprender el acceso desigual a beneficios, no únicamente para predecir la clase. En este sentido, su conservación es necesaria para mantener la validez externa del modelo, ya que lo conecta con los factores estructurales que influyen en la política pública.

3.3 Construcción e Integración de datos

Durante esta etapa se añaden a la preparación de variables y a las técnicas de reducción (del modelo) un trabajo de balanceo en la representación de los grupos sociales, evitando que la información de atributos sensibles quede sobrerrepresentada o poco visible.

En balanceo y generación de datos, el enfoque combina re-muestreo clásico y técnicas “fair”. Se emplean métodos como Random Under/Oversampling y SMOTE, de forma independiente y junto con variantes sensibles a la equidad: Fair-SMOTE (sintetiza ejemplos para subgrupos infrarrepresentados), FOS (refuerza el subgrupo protegido más escaso dentro de la clase minoritaria), FAWOS (genera muestras según densidades y tipo de variable) y DEMV (ajusta proporciones cuando hay múltiples atributos sensibles). TabFairGAN incorpora en su función de pérdida una señal que penaliza la discriminación entre grupos, produciendo nuevos datos sintéticos con menor disparidad.

En reducción de dimensionalidad, se incluye PCA para condensar información y simplificar modelos sin perder estructura global, y una variante “fair” basada en aprendizaje adversario/selección sensible que escoge atributos maximizando la representación mientras minimiza la señal del atributo sensible. Este bloque permite entrenar clasificadores con menos variables, reducir complejidad y, simultáneamente, atenuar la filtración de información sobre grupos protegidos a través de las características seleccionadas.

4. Modelado

En esta fase se prueban las técnicas y algoritmos de ML para abordar el problema en cuestión y lograr los objetivos establecidos (Chapman, et al., 2000). Los esfuerzos deben estar encaminados en cuanto los posibles riesgos y evitar poner en peligro la integridad de las personas.

4.1 Selección de técnicas de modelado

La herramienta permitió utilizar clasificadores como, árboles de decisión, métodos de Ensemble como Bagging y Boosting, clasificadores como K-nearest neighbor (KNN), Support Vector Machines (SVM), modelos lineales, clasificadores estadísticos basados en el teorema de Bayes y clasificador de análisis discriminante. Dado que cada algoritmo y técnica presenta características específicas para mejorar el rendimiento en la clasificación de los datos.

Generación de un diseño de comprobación

El problema se aborda como una clasificación binaria en la que la clase positiva corresponde a recibir el BIE ($DES_BIE_ENC = 1$) y la clase negativa a no recibirlo ($DES_BIE_ENC = 0$). Para elegir el mejor modelo se utilizaron las métricas de rendimiento definidas en el archivo JSON: $f1_score$ y $recall$, debido a que existe un desequilibrio de clases es prioritario minimizar los falsos negativos (no otorgar el beneficio a quien lo merece). Como métrica de equidad se utilizó la false negative rate difference (FNRD), que mide la diferencia en la tasa de falsos negativos entre mujeres (grupo privilegiado) y hombres (grupo no privilegiado). Un valor cercano a cero indica semejanzas de error en la asignación del beneficio entre sexos.

Imagen 1. Matriz de confusión

	Actual – Positive	Actual – Negative
Predicted – Positive	True Positive (TP) $PPV = \frac{TP}{TP+FP}$ $TPR = \frac{TP}{TP+FN}$	False Positive (FP) $FDR = \frac{FP}{TP+FP}$ $FPR = \frac{FP}{FP+TN}$
Predicted – Negative	False Negative (FN) $FOR = \frac{FN}{TN+FN}$ $FNR = \frac{FN}{TP+FN}$	True Negative (TN) $NPV = \frac{TN}{TN+FN}$ $TNR = \frac{TN}{TN+FP}$

Fairness Definitions Explained (Verma & Rubin, 2018)

En la table 9 se muestran las métricas que intervienen en los cálculos del rendimiento de los modelos, la representación está en su versión original y no en la versión de ratios o de diferencia que se utilizan para determinar la equidad entre grupos.

Tabla 9. Métricas utilizadas

Métrica	Ecuación	Descripción
Positive Predictive Value o precision	$PPV = TP/(TP + FP)$	La fracción de casos positivos predichos correctamente para estar en la clase positiva de todos los casos positivos predichos.
True Positive Rate o sensitivity o recall	$TPR = TP/(TP + FN)$	Tasa de casos positivos que se predice correctamente que están en la clase positiva de todos los casos positivos reales.
False Negative Rate	$FNR = FN/(TP + FN)$	La proporción de casos positivos que se predice incorrectamente que están en la clase negativa de todos los casos positivos reales.

F1-score: Es una medida que combina la precisión y el recall en un solo valor. Es útil cuando se desea tener un equilibrio entre la precisión y el recall. El F1-score es la media armónica de la precisión y el recall.

$$F1 - score = \frac{2 * (recall * precision)}{(recall + precision)}$$

4.2 Generación de modelos

Cada clasificador fue entrenado con los datos iniciales mediante una división de los datos de 80 % para entrenamiento y 20 % para prueba, complementada con validación cruzada de 5 folds para estimar la generalización.

En la tabla 10, muestra los valores de línea base sobre los cuales que compararan el resto de resultados. En ella se puede apreciar como RidgeClassifierCV y la Red Neuronal se destacan como los de mejor comportamiento por su equilibrio entre rendimiento y equidad. El primero alcanza el mayor recall de todos los clasificadores (0.996) y un F1-Score competitivo (0.901), acompañado de una diferencia en la tasa de falsos negativos

prácticamente nula (-0.002), lo que refleja un desempeño consistente entre grupos sensibles. La Red Neuronal, por su parte, mantiene un F1-Score de 0.900 y un recall alto (0.991), junto con una diferencia reducida en falsos negativos (-0.007).

Tabla 10. Técnicas aplicadas selección algoritmos

Clasificador	División de datos	Resultado
RidgeClassifierCV	80% entrenamiento / 20% prueba y 5-fold CV	F1=0.901; Recall=0.996; FNRD=-0.002
Red Neuronal	80% entrenamiento / 20% prueba batch_size=32 learning_rate=0.005 epochs=200 best_layers=[256,128,64], activation_function="rectify"	F1=0.900; Recall=0.991; FNRD=-0.007
LogisticRegressionCV	80% entrenamiento / 20% prueba y 5-fold CV	F1=0.898; Recall=0.979; FNRD=-0.025
GradientBoostingClassifier		F1=0.903; Recall=0.975; FNRD=-0.029
LinearDiscriminantAnalysis		F1=0.900; Recall=0.975; FNRD=-0.023
AdaBoostClassifier		F1=0.899; Recall=0.969; FNRD=-0.025
XGBClassifier		F1=0.898; Recall=0.946; FNRD=-0.044

4.3 Selección del modelo

En la tabla 11, se muestran los primeros seis resultados (de 13) de la aplicación de las técnicas de optimización y sus combinaciones. En las filas donde se muestra la reducción de dimensionalidad los atributos que fueron a utilizados fueron: AÑO_ING_NOR, NUM_HIJOS_NOR, EX_GRUPO_ENC_AUC, NIV_EDU_ENC, GRUPO_ETAR_ENC Entre 41 y 60 años, EX_GRUPO_ENC_FARC, SEXO_ENC, POS_CON_ENC, POS_SPU_ENC, REG_SAL_ENC, TIP_VIV_ENC_Casa. En la tabla se puede apreciar como las intervenciones de optimización y reducción de dimensionalidad no únicamente preservan el rendimiento del modelo, conservando más de una puntuación F1 en torno a 0.90, sino que, también, se observa un aumento del recall y, como algo más importante, de la equidad, que se observa en un FNRD más próximo a cero.

Tabla 11. Mejores resultados de aplicación de técnicas de optimización

Clasificador	División de datos	Intervención	Resultado
LinearDiscriminantAnalysis	Se dividió el conjunto de datos en dos utilizando el 80% para entrenamiento y el 20% para pruebas.	Se realizó reducción de dimensionalidad mediante PCA.	Recall=0.999 F1_score=0.898 FNRD= -0.001
RidgeClassifierCV		Optimización de hiper-parámetros con	Recall = 0.996 F1_score=0.901 FNRD = -0.002

		Grid Search store_cv_values=True	
GradientBoostingClassifier		Se realizó reducción de dimensionalidad mediante PCA.	Recall=0.992 F1_score=0.901 FNRD=-0.003
AdaBoostClassifier		Se realizó reducción de dimensionalidad mediante PCA.	Recall=0.992 F1_score=0.900 FNRD=-0.0007
GradientBoostingClassifier		Optimización de hiper-parámetros con Grid Search learning_rate: 0.05 max_depth: 4 n_estimators: 300 random_state: 10	Recall=0.991 F1_score=0.901 FNRD=-0.007
XGBClassifier		Combinación entre reducción de dimensionalidad con PCA y optimización de hiper-parámetros learning_rate:0.03 max_depth:8 n_estimators:300, seed:0	Recall=0.987 F1_score=0.900 FNRD=-0.011

5. Evaluación

Una vez establecido el modelo que se utilizará se procede nuevamente a realizar la evaluación de las métricas definidas, para revisar varios aspectos para comprender la calidad y el rendimiento del modelo (Cabrera, y otros, 2023).

5.1 Evaluación de los resultados

Es importante analizar los casos en los que el modelo ha cometido errores. Esto puede ayudar a identificar patrones o características problemáticas en los datos y proporcionar información para mejorar el modelo.

Tabla 12. Análisis de resultados

Métrica	Descripción
Para el recall , la decisión de priorizarlo responde al costo social de los falsos negativos en este caso de uso: es preferible no omitir a quien merece el BIE, aun si esto implica revisar algunos casos positivos adicionales.	La línea base mostro sensibilidades altas, por ejemplo, RidgeClassifierCV con 0.997 y la Red Neuronal con 0.991 y las optimizaciones de selección (PCA e hiper-parámetros) mejoraron más los resultados, como en LinearDiscriminantAnalysis con PCA (0.999) y GradientBoosting ajustado ($\approx 0.991-0.993$), sin sacrificar el equilibrio general del modelo. Dentro de las soluciones de Pareto, el comportamiento muestra que el recall global mediano es ≈ 0.980 y el máximo alcanza 0.9997, con cerca del 28% de las soluciones por encima

	de 0.99. Además, los experimentos etiquetados de optimización que incluyen PCA e hiper-parámetros concentran la mediana de recall en aproximadamente ≈ 0.989 , mientras que las fases de pre y posprocesamiento mantienen valores ligeramente menores.
En el F1_score, la elección obedece a que resume el balance entre precisión y recall cuando las clases están desbalanceadas y, por tanto, evita sobre-premiar la sensibilidad a costa de aumentar falsos positivos.	La línea base mostro un F1 alrededor de 0.900–0.904 y, tras las optimizaciones de selección, se observa que el F1 se conserva, lo que sugiere una estabilidad del equilibrio entre acierto y cobertura. Esa estabilidad también aparece en las soluciones de Pareto, donde F1 promedio es ≈ 0.9005 , con una variación pequeña (desviación estándar ≈ 0.0015) y un máximo de 0.9041; aproximadamente el 36 % de las soluciones superan 0.901.
En FNRD (false negative rate difference), la razón de seleccionarla es que captura de forma directa la equidad en el error más crítico del problema: compara la tasa de falsos negativos entre hombres y mujeres, y su valor objetivo es 0 (paridad de error)	En la línea base mostro disparidades bajas para los mejores modelos RidgeClassifierCV con -0.003 y la Red Neuronal con -0.008 y, tras PCA e hiper-parámetros, varias combinaciones quedan cercanas a cero, por ejemplo, LinearDiscriminantAnalysis y PCA con -0.001 , AdaBoost y PCA con -0.0007 y GradientBoosting y PCA con aproximadamente -0.0039 . En las soluciones de Pareto: a nivel global la mediana de FNRD es ≈ 0.0185 , pero en el conjunto entrenado con técnicas de optimización la mediana de FNRD desciende a ≈ 0.0043 y casi el 27 % de las soluciones logran $ FNRD \leq 0.005$. En pre y posprocesamiento, algunas intervenciones que optimizan otros criterios de equidad o de rendimiento pueden aumentar ligeramente FNRD .

6. Intervenciones de Equidad

6.1 Preprocesamiento (Comprensión y preparación de los datos)

Consiste en ajustar los datos antes de iniciar el proceso de entrenamiento. Estos métodos pueden resultar atractivos cuando se contempla la publicación de un conjunto de datos, para garantizar resultados justos a partir de modelos entrenados con ellos (Nielsen, 2020).

En la tabla 13, se muestran 5 de los 61 resultados que se tienen para la fase de preprocesamiento. Las intervenciones que encabezan estos resultados se destacan

aquellas como: Reweighter que reequilibra los pesos de las observaciones por grupo y clase para que el modelo utilice distribuciones simétricas sin cambiar los datos; FAIR_GAN genera ejemplos sintéticos controlando la mezcla entre grupos y clases para ampliar la cobertura del espacio de decisión; Disparate Impact Remover (DIR) transforma rasgos para reducir la dependencia con el atributo sensible preservando el orden relativo; la optimización de hiper-parámetros ajusta el clasificador para mejorar su ajuste; PCA reduce la dimensionalidad; Unawareness elimina el atributo sensible del entrenamiento, reduciendo su influencia directa.

En LinearDiscriminantAnalysis, la constante es PCA: con Reweighter, con Unawareness o con DIR, el recall se mantiene en 0.999138 y el FNRD queda bajo (-0.001076), manteniendo tasas semejantes entre grupos. La diferencia aparece en F1: Reweighter y PCA logra el mejor equilibrio (0.898850), Unawareness y PCA queda apenas por detrás (0.898734) y DIR y PCA cede un poco más (0.898502). Estos resultados indican que cuando la representación ya estabiliza la equidad, reponderar conserva mejor la señal predictiva que remover el atributo sensible o aplicar una reparación.

En la misma tabla, CalibratedClassifierCV, aplicando solamente la supresión del atributo sensible o la remoción del tratamiento dispar se logra mejorar el rendimiento (recall=0.996841) y reduce la disparidad de falsos negativos (FNRD=-0.002149), el F1=0.901441 aumenta, lo que indica que el aumento de cobertura no vino acompañado de un aumento relevante de falsos positivos.

Tabla 13. Resultados preprocesamiento

Clasificador	Intervención	Recall	F1	FNRD
LinearDiscriminantAnalysis	REWEIGHTER y PCA	0.999138	0.898850	-0.001076
	UNWARENESS y PCA	0.999138	0.898734	-0.001076
	DIR y PCA	0.999138	0.898502	-0.001076
CalibratedClassifierCV	UNWARENESS	0.996841	0.901441	-0.002149
	DIR	0.996841	0.901441	-0.002149

6.2 Procesamiento (Modelado)

En este caso los datos originales no se ajustan, sino que se optimiza un modelo para que además de ser preciso sea justo. Generalmente, se aplica cuando los conjuntos de datos son tan grandes que las intervenciones de preprocesamiento no son viables debido a los recursos computacionales (Nielsen, 2020).

En la tabla 14, se muestran los dos únicos resultados que estuvieron dentro de la frontera de Pareto. En esta tabla se aprecia que estas intervenciones, como por ejemplo Fairness for Free en combinación con DIR, introducen durante el entrenamiento una restricción de equidad en “equidad diferencial” que es calculada a partir de las distribuciones estimadas del atributo protegido en los datos. Comparado contra los resultados de la línea base, Fairness for Free eleva el recall a 999426, aumenta el F1 a 0.901671 y, reduce FNRD a -0.000718. La combinación entre PREJUDICE_REMOVER con DIR aunque están dentro de la frontera de Pareto, no superan la línea base.

Tabla 14. Resultados procesamiento

Clasificador	Intervención	Recall	F1	FNRD
NEURONAL_NETWORK	FAIR FOR FREE y DIR	0.999426	0.901671	-0.000718
NEURONAL_NETWORK	PREJUDICE_REMOVER y DIR	0.980471	0.899723	-0.011815

6.3 Post- procesamiento (Evaluación)

Estos métodos están encaminados a buscar la generación de resultados más justos, con una serie de métricas que se encargan de establecer la injusticia que produce el modelo al ser generados con datos que no han sido procesados pensando en la equidad. Estas medidas generalmente se basan en la comparación entre grupos en lugar de individuos (Nielsen, 2020).

En la tabla 15, se muestran los 5 mejores resultados de los 52 que tienen las intervenciones de procesamiento. En la tabla se puede ver como la intervención basada en Equalized Odds Postprocessing, que ajusta etiquetas/umbrales por grupo para que falsos negativos y falsos positivos queden semejantes entre poblaciones, corrigiendo la salida sin reentrenar el modelo. Esto produjo que GradientBoosting el recall sube de la línea base a 0.995692, la FNRD disminuye a 0.001808 y el F1 se mantiene en 0.900169. En XGBClassifier esta intervención produce un recall de 0.991384, el F1 se mejora ligeramente a 0.898 y la FNRD pasa a -0.001776, esto sugiere que se neutraliza la disparidad manteniendo el equilibrio rendimiento-equidad. Que “EqOdds + HYPERPARAMETER” repita exactamente las cifras de “EqOdds” en XGB y que, en GradientBoosting, el ajuste fino deje métricas muy próximas (recall 0.991097; F1 0.898698; FNRD -0.002135) sugiere que, una vez el post-proceso reetiqueta en la frontera de decisión para igualar tasas de error entre grupos, la rejilla de hiperparámetros aporta poco margen adicional sobre esas tres métricas clave.

Reject Option Classification, también de posprocesamiento, reetiqueta casos “dudosos” para reducir discriminación en la salida. Sus resultados con AdaBoost muestran el patrón esperado: el recall mejora frente a la base (0.985066 vs. 0.970, +0.0151), el F1 sube levemente (0.900499 vs. 0.900) y la FNRD disminuye en magnitud de 0.025 a 0.018658 (mejora absoluta ≈ 0.0063). En términos prácticos, ROC mitiga parte de la disparidad y conserva el nivel de F1, pero Equalized Odds logra una paridad mucho más cercana a cero con recalls más altos en los ensambles de gradiente, lo que la hace preferible cuando el objetivo es balancear fuertemente los errores entre grupos sin sacrificar sensibilidad.

Tabla 15. Resultados posprocesamiento

Clasificador	Intervención	Recall	F1	FNRD
GradientBoostingClassifier	EqOddsPostprocessing	0.995692	0.900169	0.001808
XGBClassifier	EqOddsPostprocessing	0.991384	0.898607	-0.001776
XGBClassifier	EqOddsPostprocessing y HYPERPARAMETER	0.991384	0.898607	-0.001776
GradientBoostingClassifier	EqOddsPostprocessing y HYPERPARAMETER	0.991097	0.898698	-0.002135
AdaBoostClassifier	RejectOptionClassification	0.985066	0.900499	-0.018658

6.4 Reporte final

Al finalizar el entrenamiento, se obtiene un conjunto de modelos construidos mediante intervenciones de equidad que cumplen con los criterios de la frontera de Pareto. Las métricas asociadas a estos modelos son analizadas para identificar las intervenciones más prometedoras, las cuales se considerarán en la recomendación final sobre las fases más apropiadas del proceso de machine learning para implementar dichas intervenciones.

Como se muestra en la tabla 16, se muestran las combinaciones de intervenciones que produjeron los resultados que superaron la línea base. Los resultados iniciales fueron para F1 de 0.9012, recall de 0.9965, y FNRD fue de 0.0025. Estos mismos resultados se muestran en la primera fila y fueron logrados haciendo optimización de hiper-parámetros y/o supresión del atributo sensible y/o aplicando remoción DI. Pero esos valores fueron superados por CalibratedClassifierCV mediante técnicas de preprocesamiento y/o en combinación con técnicas de optimización. El siguiente mejor resultado se produce realizando la intervención directamente en el entrenamiento añadiendo a la función de pérdida una penalización basada en la equidad diferencial, calculada a partir de las distribuciones estimadas de los atributos protegidos (FAIR_FOR_FREE). Esta combinación de intervenciones supero tanto en rendimiento como en equidad a la línea base. Con relación a las intervenciones de posprocesamiento.

Tabla 16. Resumen resultados

Clasificador	Intervención	Métricas rendimiento	Métricas equidad	Observación
RidgeClassifierCV	HYPERPARAMETER	Recall=0.9965 F1=0.9012	FNRD=- 0.0025	El ajuste de hiper-parámetros afina el modelo
CalibratedClassifierCV	DIR	Recall=0.9968 F1=0.9014	FNRD=- 0.0021	La remoción de impacto dispar (DIR) redujo diferencias entre grupos sin afectar el rendimiento
CalibratedClassifierCV	HYPERPARAMETER - DIR	Recall=0.9968 F1=0.9014	FNRD=- 0.0021	La combinación de ajuste de hiper-parámetros con DIR estabiliza las métricas y mantuvo FNRD bajo.
CalibratedClassifierCV	HYPERPARAMETER - UNAWARENESS	Recall=0.9968 F1=0.9014	FNRD=- 0.0021	Ajuste de hiper-parámetros más exclusión del atributo sensible evita


				dependencia directa y sostuvo F1/recall con FNRD bajo
CalibratedClassifierCV	UNAWARENESS	Recall=0.9968 F1=0.9014	FNRD=-0.0021	Excluir el atributo sensible no degrada el rendimiento y mantuvo controlada la disparidad de falsos negativos
Red Neuronal	FAIR_FOR_FREE - DIR	Recall=0.9994 F1=0.9016	FNRD=-0.0007	La regularización Fair for Free combinada con DIR acerca la disparidad de FN a cero.

6.5 Proceso de revisión

Luego de tener resultados de evaluación del modelo se pueden establecer un conjunto de acciones para comprender cómo se toman las decisiones. Los valores que se exponen en las figuras 7 y 8, son la media de la importancia que cada una de las características tuvo en las decisiones de los modelos que lograron el mejor equilibrio entre rendimiento y equidad. Dichos valores son aquellos que se obtuvieron en la resolución de un procedimiento que combinaba la reevaluación de los datos (imitando un proceso de generación de resultados) y la explicación de las predicciones de forma que cada atributo quedaba vinculado a un peso proporcional a su contribución a la generación de resultados. En estas figuras ayudan a decidir cuál de los clasificadores le proporciona menor importancia al atributo sensible.


La figura 7, muestra la importancia que se le dio al atributo sexo por los diferentes clasificadores que fueron utilizados para determinar cuáles de ellos a pesar tener una adecuada compensación entre rendimiento y equidad, también le dan una importancia menor al atributo sensible. Como se puede observar como el clasificador RidgeClassifierCV, en combinación con las optimización de hiper-parámetros disminuye la importancia del atributo SEXO_ENC en la clasificación.

Figura 7. Importancia por clasificador atributo sexo



La figura 8, muestra las importancias absolutas ($|SHAP|$) de cada atributo por clasificador, ordenando los modelos según la contribución de SEXO_ENC. Se observa que ambos clasificadores dependen menos de SEXO_ENC, pero los colores sugieren mayor sensibilidad en atributos individuales como EX_GRUPO_ENC_AUC y REG_VIV_ENC_Otra_forma. En conjunto con los resultados previos de compensación rendimiento-equidad, este hallazgo respalda a dicho modelo como la alternativa con mejor balance. Como el criterio de selección prioriza minimizar la dependencia del modelo respecto del atributo sensible, la elección recomendada es RidgeClassifierCV_HYPERPARAMETER. El mapa de calor sugiere que CalibratedClassifierCV distribuye pesos de forma más uniforme a nivel global, pero para el atributo sensible en particular muestra mayor sensibilidad.

Figura 8. Importancia por clasificador todos los atributos



REFERENCIAS

- Cabrera, Á. A., Fu, E., Bertucci, D., Holstein, K., Talwalkar, A., Hong, J. I., & Perer, A. (2023). Zeno: An Interactive Framework for Behavioral Evaluation of Machine Learning. *CHI Conference on Human Factors in Computing Systems* (págs. 1-14). Hamburg: ACM.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step Data Mining Guide*. SPSS.
- Fahse, T., Huber, V., & van Giffen, B. (2021). Managing Bias in Machine Learning Projects. En F. Ahlemann, R. Schütte, & S. and Stieglitz, *Innovation Through Information Systems* (págs. 94--109). Cham: Springer International Publishing.
- Holland, S., Hosny, A., Newman, S., Joseph, J., & Chmielinski, K. (2018). The Dataset Nutrition Label: A Framework To Drive Higher Data Quality Standards. *arXiv*, 1-21.
- Martínez-Plumed, F., Contreras-Ochando, L., Ferri, C., Hernández-Orallo, J., Kull, M., Lachiche, N., . . . Flach, P. (2021). CRISP-DM twenty years later: from Data Mining processes to Data Science trajectories. *IEEE Transactions on knowledge and data engineering*, 3048-3061.
- Nielsen, A. (2020). *Practical Fairness Achieving Fair and Secure Data Models*. Sebastopol: O'Reilly.
- Piorkowski, D., Richards, J., & Hind, M. (2022). Evaluating a Methodology for Increasing AI Transparency: A Case Study. *arXiv*, 1-15.
- Saltz, J., & Hotz, N. (2020). Identifying the most Common Frameworks Data Science Teams Use to Structure and Coordinate their Projects. *IEEE International Conference on Big Data (Big Data)* (págs. 2038-2042). Virtual: IEEE.
- Verma, S., & Rubin, J. (2018). Fairness Definitions Explained. *International Conference on Software Engineering* (págs. 1-7). Gotemburgo: IEEE/ACM.