


PINKFAIRNESS

GUÍA DE PROCESO DE DATA MINING CON ENFOQUE DE EQUITAD

El presente documento tiene como propósito ofrecer una guía práctica para llevar a cabo un proceso de Machine Learning (ML) con un enfoque en la equidad. La guía se basa en un enfoque estructurado, compuesto por fases y tareas definidas, complementado con un conjunto de herramientas diseñadas específicamente para explorar datos en busca de sesgos y desarrollar modelos que promuevan la equidad (Fahse, Huber, & van Giffen, 2021).

La figura 1, ilustra el conjunto de fases que estructura modularmente el Framework, estas fases avanzan de manera secuencial. Inicialmente, se establecen las razones que motivan la construcción del modelo. Luego, se procede a comprender los datos que serán utilizados y, posteriormente, a prepararlos para el entrenamiento. En las fases de modelado, evaluación e intervenciones de equidad, se genera un ciclo en el que los modelos son entrenados con diferentes tipos de intervención y evaluados para determinar su efectividad. Según las consideraciones del proyecto y la mejora con respecto a la línea base, el usuario puede optar por reprocesar los datos con enfoques alternativos y repetir el proceso de entrenamiento, evaluación e intervención de equidad para obtener mejores resultados.

Figura 1. Fases que conforman el framework



Fuente: Autor

1. Motivación

El conjunto de datos original fue suministrado por la Subdirección de Gestión de Información en Justicia, que pertenece al Ministerio de Justicia de Colombia y corresponden al tiempo de condena de la población privada de la libertad (PPL) que ya tiene registro en el sistema misional del Instituto Nacional Penitenciario y Carcelario (INPEC), la pena que le fue impuesta por la autoridad competente.

Este documento justifica y enmarca la implementación de PinkFairness en el caso población privada de la libertad en Colombia (PPL). El problema a resolver se formula como una tarea de clasificación binaria: dado el expediente de una persona, clasificar si reincidirá (1) o no reincidirá (0).

Tabla 1. Requisitos generales

Requisito	Descripción
Población objetivo	PPL en procesos de reintegración; equipos profesionales de seguimiento psicosocial y jurídico; autoridades responsables de asignación de programas y medidas de acompañamiento; entidades de política pública y control.
Contexto	Predicción del riesgo de reincidencia con ML, minimizando falsos positivos/negativos y mitigando sesgos de género.
Datos sensibles	ENC_GENERO (0 = femenino, 1 = masculino). Datos provenientes de la plataforma de datos abiertos de Colombia. Las mujeres son consideradas el grupo vulnerable.
Limitaciones	Dependencia de la calidad y completitud de los datos; sesgos históricos; desbalance de clases; riesgo de deriva por cambios en población o procedimientos; incertidumbre de los modelos. Requiere validación periódica y contraste con juicio profesional.
Beneficios	Mejor priorización de recursos; mayor consistencia entre evaluaciones; trazabilidad de criterios y decisiones; capacidad de medir y reducir disparidades entre subgrupos; facilidades de explicación y auditoría.
Implicaciones éticas	Uso responsable con supervisión humana para evitar decisiones injustas o refuerzo de sesgos existentes.
Mantenimiento	Se persigue que el modelo sea recalibrado cada seis meses o bien cuando se incorporan unas 500 nuevas evaluaciones, lo que acontezca primero. El recall (clase positiva = reincidente) es una métrica de la proporción de reincidentes que se clasifican correctamente. La precisión indica la proporción de reincidencias de las predicciones verdaderas y se vuelve especialmente importante cuando existen consecuencias de etiquetar erróneamente a alguien como reincidente. El F1-score es la métrica que contiene el equilibrio entre la precisión y el recall. En cuanto a la equidad, el Disparate Impact (DI) es una métrica que expresa la razón entre las tasas de decisión positiva entre los grupos y se persigue que esté cerca de 1, mientras que la Diferencia en la Tasa de Falsos Positivos (FPR Difference) representa las personas incorrectamente clasificadas como reincidentes entre subgrupos.

2. Comprensión de los datos

Implica un análisis de los datos disponibles para la construcción del modelo. Este paso ayuda a prevenir inconvenientes imprevistos durante la siguiente etapa (Chapman, et al., 2000) (Saltz & Hotz, 2020).

2.1 Recopilación de datos iniciales

El conjunto de datos se descargó de la plataforma de datos abiertos del Instituto Nacional Penitenciario y Carcelario (INPEC) y contiene registros de personas sindicadas por uno o más delitos entre 1997 y 2021. No se identificaron valores nulos en las variables, por lo que no fue necesario imputar datos. Los datos se encuentran en formato CSV y se utilizaron tal cual sin preprocesamiento adicional para la exploración inicial.

Tabla 2. Descripción general del dataset

Ítem	Descripción
Fuente de Datos	INPEC – datos abiertos de Colombia
Filas	24.713 registros (entrenamiento + prueba).
Columnas	20 atributos de entrada.
Atributos sensibles	ENC_GENERO (0 = femenino, 1 = masculino).
Atributo de clase	ENC_REINCIDENTE (0 = no reincidente, 1 = reincidente).
Formato	CSV con codificación numérica de categorías.
Descripción	Datos demográficos, historial delictivo, duración de condena y variables de régimen penitenciario.

2.2 Descripción de los datos

En esta sección se busca comprender la naturaleza y las características de cada atributo en el conjunto de datos. Esto implica examinar el tipo de dato, la escala de medición, el rango de valores posibles, la presencia de valores atípicos o perdidos, y cualquier otra información relevante relacionada con cada atributo (Holland, Hosny, Newman, Joseph, & Chmielinski, 2018) (Piorkowski, Richards, & Hind, 2022) (Martínez-Plumed, et al., 2021).

Tabla 3. Descripción de atributos

Atributo	Descripción
ENC_HOMICIDIO	Condena por homicidio.
ENC_HURTO	Condena por hurto.
ENC_FATRAPORTE_ARMAS_MUNICIONES	Delitos de armas y municiones.
ENC_TRAFAPORTE_ESTUPEFACIENTES	Delitos de estupefacientes.
ENC_CONCIERTO_DELINQUIR	Concierto para delinquir.
ENC_ACTOS_SEXUALES_MENOR_14	Actos sexuales con persona menor de 14 años.
ENC_ACC_CARNAL_14	Acceso carnal con persona menor de 14 años.
ENC_INTRAMUROS	Régimen intramuros (1) vs extramuros (0).
ENC_MESES_CONDENAS	Duración de la pena en meses.
ENC_ANNO_INGRESO	Año de ingreso según sentencia.
ENC_RANGOS_EDAD_INPEC	Categoría de edad al ingreso (1–10).
ENC_GENERO	Género: 1 = masculino, 0 = femenino.
ENC_NIVEL_EDUCATIVO	Nivel educativo (1–9).

ENC_REGIONAL_*	Tiene seis atributos uno por cada regional en la cual se divide el país los valores de los atributos que puede tomar son: CENTRAL, OCCIDENTE, NOROESTE, NORTE, ORIENTE, VIEJO_CALDAS.
----------------	---

Tabla 4. Estadística atributos ordinales y nominales


Atributo	tipo	cantidad	Valores únicos	Mas frecuentes	Menos frecuentes	% nulos
ENC_GENERO	category	24713	2	1	0	0
ENC_NIVEL_EDUCATIVO	category	24713	9	3	9	0
ENC_RANGOS_EDAD_INPEC	category	24713	10	2	10	0
ENC_INTRAMUROS	category	24713	2	1	0	0
ENC_ACC_CARNAL_14	category	24713	2	0	1	0
ENC_ACTOS_SEXUALES_MENOR_14	category	24713	2	0	1	0
ENC_CONCIERTO_DELINQUIR	category	24713	2	0	1	0
ENC_FATRAPORTE_ARMAS_MUNICIONES	category	24713	2	0	1	0
ENC_HOMICIDIO	category	24713	2	0	1	0
ENC_HURTO	category	24713	2	0	1	0
ENC_TRAFAPORTE_ESTUPEFACIENTES	category	24713	2	0	1	0
ENC_REGIONAL_CENTRAL	category	24713	2	0	1	0
ENC_REGIONAL_NOROESTE	category	24713	2	0	1	0
ENC_REGIONAL_NORTE	category	24713	2	0	1	0
ENC_REGIONAL_OCCIDENTE	category	24713	2	0	1	0
ENC_REGIONAL_ORIENTE	category	24713	2	0	1	0
ENC_REGIONAL_VIEJO_CALDAS	category	24713	2	0	1	0
ENC_REINCIDENTE	category	24713	2	0	1	0

Tabla 5. Estadística atributos continuos y discretos

Atributo	tipo	cantidad	mínimo	media	máximo	media	Des Est	% nulos	% ceros
ENC_ANNO_INGRESO	int 64	24713	1997	2018	2021	2017.615933	2.395119	0	0
ENC_MESES_CONDEÑA	int 64	24713	0	91	720	129.380931	113.355656	0.0	0

En la figura 2, se muestra la distribución del atributo que se utilizará como clase con sus valores originales, indicando la cantidad por clase y el porcentaje al cual equivale dentro de todo el conjunto de datos.

Figura 2. Distribución del atributo de clase



La tabla 6, muestra la distribución de los conjuntos de datos de entrenamiento y pruebas, divididos por clase y atributo sensible. En esta división las clases siguen la misma distribución donde los valores negativos son mayores que los positivos. Adicionalmente, el sexo masculino tiene la mayor cantidad de reincidentes y de no reincidentes, mientras que las mujeres tienen valores menores.

Tabla 6. Distribución clases y atributos sensibles desmovilizados

Conjunto	S=M C=1	S=M C=0	S=F C=1	S=F C=0
Entrenamiento	5227	12753	352	1438
Pruebas	1303	3203	92	345

2.3 Exploración de datos


En esta sección se describen las relaciones entre atributos que reflejan comportamiento de incremento o decremento entre ellas y que guardan alguno tipo de relación en cuanto a la distribución de sus valores, los valores de clase y se segmentan por atributos sensibles, por lo tanto, se visualizaran dos graficas una que refleja la distribución para ese grupo sensible.

En los gráficos que se mostraran, las categorías están ubicadas en el eje x, la altura de la barra indica el número de registros. El contorno sólido corresponde a Clase = 0 y el contorno punteado a Clase = 1. Los colores apilados dentro de la barra describen la distribución de la variable auxiliar (leyenda).

En la figura 3, se muestra que, a partir de 2012-2014, ambos grupos de ENC_GENERO muestran una progresiva disminución de los plazos de condena y fluctuaciones asociadas a estos plazos, mientras que en los primeros años del 2000 las condenas, así como la variabilidad asociada a la condena de ENC_GENERO = 1 son más altas, incluso generando picos en los años 2008-2011, que el grupo ENC_GENERO = 0 en estos últimos años que muestra un aumento temporal entre los años 2009-2012 seguido de la caída y estabilización de los plazos de condena en los años 2016-2018. Las diferencias de clases son moderadas en cada uno de los paneles: para ENC_GENERO = 1 la clase naranja se aproxima a medias algo menores que la azul en los años 2010-2014; y para ENC_GENERO = 0, las dos clases


se acercan en los años recientes. En conclusión, las condenas se van reduciendo y volviendo menos diferenciadas; las brechas de género iniciales se van reduciendo con la llegada de los años más recientes.

Figura 3. Exploración entre el año de ingreso y los meses de condena



La figura 4, muestra la distribución de ENC_MESES_CONDENA en función de la categorización de ENC_NIVEL_EDUCATIVO de cada persona, separado por ENC_GENERO y coloreando por Clase. En ENC_GENERO=1 las diferencias observadas entre Clase tienden a ser moderadas, a excepción de la categoría 7, donde Clase=1 es más elevada que Clase=0; en el resto de categorías el rango entre estos es pequeño. En caso de ENC_GENERO=0, muestra puntuaciones inferiores y una limitación de la dispersión observada, a excepción de la categoría 8, donde Clase=0 presenta una tendencia a condenas menos esperadas y una variabilidad mayor. Por lo tanto, hay un patrón que puede sugerir la existencia de una interacción entre la educación recibida y el género de la persona sobre la duración de la condena.

Figura 4. Distribución entre nivel educativo y meses de condena



En la tabla 7, se muestran las relaciones que se identificaron entre atributos utilizando la visualización de comprensión de los datos y mediante las pruebas numéricas que identifica las relaciones entre todas las variables, cómo estas influyen en la clase que se quiere predecir, y su asociación con el atributo sensible.

Tabla 7. Relación entre atributos

Relación de Atributos		Afirmación
Atributo 1	Atributo 2	
ENC_ANNO_INGRESO	ENC_MESES_CONDENADA	Se observa relación entre el año de ingreso y la duración de la condena; esto podría reflejar cambios normativos o de política criminal a lo largo del tiempo, por lo que es coherente con el mundo real. Sin embargo, esto puede producir que el año funcione como proxy de composición demográfica.
ENC_NIVEL_EDUCATIVO	ENC_RANGOS_EDAD_INPEC	El nivel educativo se encuentra condicionado por la edad, lo que puede introducir dobles conteos de información.

2.4 Verificación de calidad de datos

Luego de la exploración de los datos, se determina qué atributos deben ser intervenidos y cómo se debería realizar dicha intervención.

Tabla 8. Calidad de datos

Atributo	Problema	Intervención	Repercusión
ENC_GENERO	Distribución altamente desbalanceada (≈91% hombres y 9 % mujeres).	Aplicar técnicas de re-muestreo (SMOTE, ROS) para equilibrar subgrupos durante el entrenamiento.	El balanceo aumenta la representación del grupo, pero esto altera la proporción real de géneros en el conjunto de datos. Esta situación puede beneficiar o empeorar la equidad
ENC_ACTOS_SEXUALES_MENOR_14 y ENC_ACC_CARNAL_14	Muy pocos casos; correlación alta entre ambos.	Agrupar estos delitos en una categoría “Delitos sexuales” o eliminarlos si su presencia es marginal.	Aunque técnicamente puede mejorar el rendimiento del modelo, esto no obedece al mundo real, puesto que

			estos dos delitos no necesariamente se dan en simultaneo y la forma en que están representados como obedece a la información original.
Variables de región	Variables mutuamente excluyentes generan correlaciones negativas y no aportan orden.	Considerar reducción dimensional (PCA) si se observa multicolinealidad.	La reducción puede simplificar el modelo y perder el seguimiento a la regional donde se encuentra el condenado. Es mejor mantener codificación one-hot

3. Preparación de los datos

En esta etapa los datos deben ser intervenidos con el fin de que tengan las representaciones adecuadas tanto del caso de uso que se está solucionando como el formato que requiere el algoritmo que implementa la tarea que se desea desarrollar (Martínez-Plumed, et al., 2017). Sin embargo, como el alcance del Framework va desde los datos preprocesados, en esta etapa solo se contempla lo relacionado con examinar cómo las características sensibles están relacionadas con otras variables en el conjunto de datos.

3.1 Selección de datos

Para seleccionar las características que alimentan el modelo se eliminaron variables con varianza cero (no se encontraron) y atributos redundantes. ENC_ACC_CARNAL_14 con ENC_ACTOS_SEXUALES_MENOR_14, que coincide como relevante en dos métricas (Chi-cuadrado y Mutual Information). Además, se observa un patrón fuerte alrededor de ENC_ANNO_INGRESO, especialmente con ENC_MESES_CONDENADA (aparece en tres métricas) y, en menor medida, con ENC_HOMICIDIO. Sugieren heterogeneidad territorial que puede ser relevante. Sin embargo, dado que algunas de estas variables también presentan divergencias con el sexo, se decidió normalizarlas o discretizarlas y vigilar su impacto durante la modelización.

La herramienta de exploración de datos identificó 69 grupos de instancias donde las características no sensibles son idénticas, pero pertenecen a diferentes géneros y tienen etiquetas distintas de reincidencia. Estos casos no indican posibles inconsistencias en el etiquetado porque la reincidencia refleja el comportamiento individual de cada acusado.

3.2 Limpieza de datos y formateo de datos

Aunque esta relación identificada en la sección anterior puede reflejar inequidades estructurales (por ejemplo, diferencias regionales), eliminarlos o transformarlos en exceso implicaría perder información del contexto social y económico en el que se toman las decisiones reales. Dichos atributos permiten comprender el acceso desigual a beneficios, no únicamente para predecir la clase. En este sentido, su conservación es necesaria para mantener la validez externa del modelo, ya que lo conecta con los factores estructurales que influyen en la política pública.

3.3 Construcción e Integración de datos

Durante esta etapa se añaden a la preparación de variables y a las técnicas de reducción (del modelo) un trabajo de balanceo en la representación de los grupos sociales, evitando que la información de atributos sensibles quede sobrerrepresentada o poco visible.

En balanceo y generación de datos, el enfoque combina re-muestreo clásico y técnicas “fair”. Se emplean métodos como Random Under/Oversampling y SMOTE, de forma independiente y junto con variantes sensibles a la equidad: Fair-SMOTE (sintetiza ejemplos para subgrupos infrarrepresentados), FOS (refuerza el subgrupo protegido más escaso dentro de la clase minoritaria), FAWOS (genera muestras según densidades y tipo de variable) y DEMV (ajusta proporciones cuando hay múltiples atributos sensibles). TabFairGAN incorpora en su función de pérdida una señal que penaliza la discriminación entre grupos, produciendo nuevos datos sintéticos con menor disparidad.

En reducción de dimensionalidad, se incluye PCA para condensar información y simplificar modelos sin perder estructura global, y una variante “fair” basada en aprendizaje adversario/selección sensible que escoge atributos maximizando la representación mientras minimiza la señal del atributo sensible. Este bloque permite entrenar clasificadores con menos variables, reducir complejidad y, simultáneamente, atenuar la filtración de información sobre grupos protegidos a través de las características seleccionadas.

4. Modelado

En esta fase se prueban las técnicas y algoritmos de ML para abordar el problema en cuestión y lograr los objetivos establecidos (Chapman, et al., 2000). Los esfuerzos deben estar encaminados en cuento los posibles riesgos y evitar poner en peligro la integridad de las personas.

4.1 Selección de técnicas de modelado

La herramienta permitió utilizar clasificadores como, árboles de decisión, métodos de Ensemble como Bagging y Boosting, clasificadores como K-nearest neighbor (KNN), Support Vector Machines (SVM), modelos lineales, clasificadores estadísticos basados en el teorema de Bayes y clasificador de análisis discriminante. Dado que cada algoritmo y técnica presenta características específicas para mejorar el rendimiento en la clasificación de los datos.

4.2 Generación de un diseño de comprobación

El problema es de clasificación binaria donde la clase positiva corresponde a reincidente (valor 1) y la clase negativa a no reincidente (valor 0). Para evaluar el rendimiento se eligieron las métricas de precisión, recall y F1-score, ya que equilibran el costo de falsos positivos y falsos negativos. Como métricas de equidad se utilizaron el Disparate Impact (proporción de decisiones positivas entre grupos) y la Diferencia en la tasa de falsos positivos, que miden la imparcialidad entre géneros.

Imagen 1. Matriz de confusión

	Actual – Positive	Actual – Negative
Predicted – Positive	True Positive (TP) $PPV = \frac{TP}{TP+FP}$ $TPR = \frac{TP}{TP+FN}$	False Positive (FP) $FDR = \frac{FP}{TP+FP}$ $FPR = \frac{FP}{FP+TN}$
Predicted – Negative	False Negative (FN) $FOR = \frac{FN}{TN+FN}$ $FNR = \frac{FN}{TP+FN}$	True Negative (TN) $NPV = \frac{TN}{TN+FN}$ $TNR = \frac{TN}{TN+FP}$

Fairness Definitions Explained (Verma & Rubin, 2018)

En la table 9 se muestran las métricas que intervienen en los cálculos del rendimiento de los modelos, la representación está en su versión original y no en la versión de ratios o de diferencia que se utilizan para determinar la equidad entre grupos.

Tabla 9. Métricas utilizadas

Métrica	Ecuación	Descripción
Positive Predictive Value o precision	$PPV = TP/(TP + FP)$	La fracción de casos positivos predichos correctamente para estar en la clase positiva de todos los casos positivos predichos.
True Positive Rate o sensitivity o recall	$TPR = TP/(TP + FN)$	Tasa de casos positivos que se predice correctamente que están en la clase positiva de todos los casos positivos reales.
False Positive Rate	$FPR = FP/(FP + TN)$	La tasa de casos negativos que se predice incorrectamente que están en la clase positiva de todos los casos negativos reales.

F1-score: Es una medida que combina la precisión y el recall en un solo valor. Es útil cuando se desea tener un equilibrio entre la precisión y el recall. El F1-score es la media armónica de la precisión y el recall.

$$F1 - score = \frac{2 * (recall * precision)}{(recall + precision)}$$

Disparate impact (DI): Corresponde a la comparación de las tasas de resultados positivos entre los grupos privilegiado y no privilegiado (Nielsen, 2020) (Caton & Haas, 2020) (Mehrabi, Morstatter, Saxena, Lerman, & Galstyan, 2019) (Calmon, Wei, Vinzamuri, Ramamurthy, & Varshney, 2017).

$$DI = \frac{\frac{TP_p + FP_p}{N_p}}{\frac{TP_u + FP_u}{N_u}}$$

4.3 Generación de modelos

Cada clasificador fue entrenado con los datos iniciales mediante una división de los datos de 80 % para entrenamiento y 20 % para prueba, complementada con validación cruzada de 5 folds para estimar la generalización.

Como se muestra en la tabla 10, el mejor rendimiento bruto lo alcanza GaussianNB, pero con señales de inequidad y diferencia de FPR, lo que indica ausencia de positivos para el grupo protegido; QDA logra un F1=0,451 y recall=0,562, aunque también muestra disparidades relevantes (DI=0,105; FPR-diff=-0,356). En el extremo opuesto, DecisionTreeClassifier exhibe el perfil más equilibrado en equidad (DI=0,911; FPR-diff=-0,021) a costa de un rendimiento (F1=0,375; recall=0,373). Los ensambles y métodos de gradiente (XGBClassifier, ExtraTree, ExtraTrees) quedan en un punto intermedio, mientras que la red neuronal es la más débil en desempeño y equidad (F1=0,227; DI=0,033).

Tabla 10. Técnicas aplicadas selección algoritmos

Clasificador	División de datos	Resultado
GaussianNB	Conjuntos de datos 80% entrenamiento y 20% pruebas. Mediante <i>cross-validation</i> de 5 folds.	f1_score=0.473403 recall=0.730466 precision=0.350172 disparate_impact=0 false_positive_rate_difference=-0.590384
QuadraticDiscriminantAnalysis (QDA)		f1_score=0.451223 recall=0.562007 precision=0.376923 disparate_impact=0.105165 false_positive_rate_difference=-0.356459
DecisionTreeClassifier		f1_score=0.375495 recall=0.373477 precision=0.377536 disparate_impact=0.91077 false_positive_rate_difference=-0.020958
XGBClassifier		f1_score=0.371183 recall=0.278853 precision=0.554922 disparate_impact=0.428995

		false_positive_rate_difference=-0.06209
ExtraTreeClassifier		f1_score=0.370506 recall=0.362007 precision=0.379414 disparate_impact=0.738887 false_positive_rate_difference=-0.052395
ExtraTreesClassifier		f1_score=0.346484 recall=0.289606 precision=0.431163 disparate_impact=0.411991 false_positive_rate_difference=-0.098981
Red Neuronal	80% entrenamiento / 20% prueba batch_size=32 learning_rate=0.005 epochs=200 best_layers=[256,128,64], activation_function="rectify"	f1_score=0.227033 recall=0.139068 precision=0.617834 disparate_impact=0.032943 false_positive_rate_difference=-0.037465

4.4 Selección del modelo

En la tabla 11, se muestra como la combinación de balanceo por sobre-muestreo (ROS) con ajuste de hiper-parámetros en XGBClassifier ofrece el mejor comportamiento global en desempeño, respaldado por validación cruzada. Muy cerca queda la variante con submuestreo (RUS), que mantiene un rendimiento competitivo pese a reducir datos. El árbol de decisión se muestra como la alternativa más equilibrada cuando se considera la equidad, pues presenta señales más estables de paridad entre grupos, aunque cede algo de rendimiento.

Tabla 11. Técnicas aplicadas selección algoritmos

Clasificador	División de datos	Intervención	Resultado
XGBClassifier	Los datos de esta intervención están distribuidos mediante ROS con: S=M C=1:13285, S=M C=0:12753, S=F C=1:906, S=F C=0:1438. Y fue utilizado <i>cross-validation</i> a 5 folds.	Además del balanceo de los datos fue necesario realizar optimización de hiper-parámetros. Siendo para este clasificador los siguientes: base_score=None, booster=None, callbacks=None, colsample_bylevel=None, colsample_bynode=None,	f1_score=0.516752 recall=0.65233 precision=0.427833 disparate_impact=0.540816 false_positive_rate_difference=-0.164836
	Los datos de esta intervención están distribuidos mediante RUS con: S=M C=1:5227, S=M C=0:5016, S=F		f1_score=0.508919 recall=0.65448 precision=0.416325 disparate_impact=0.581123 false_positive_rate_difference=-0.162029

DecisionTreeClassifier	C=1:352, S=F C=0:563. Y fue utilizado <i>cross-validation</i> a 5 folds.	colsample_bytree=None, device=None, early_stopping_rounds=None, enable_categorical=False, eval_metric='logloss', feature_types=None, gamma=None, grow_policy=None, importance_type=None, interaction_constraints=None, learning_rate=0.1, max_bin=None, max_cat_threshold=None, max_cat_to_onehot=None, max_delta_step=None, max_depth=2, max_leaves=None, min_child_weight=None, missing=nan, monotone_constraints=None, multi_strategy=None, n_estimators=300, n_jobs=None, num_parallel_tree=None, random_state=None	f1_score=0.503003 recall=0.690323 precision=0.395645 disparate_impact=0.913068 false_positive_rate_difference=-0.035437
XGBClassifier		Sin intervención	f1_score=0.499303 recall=0.641577 precision=0.408676 disparate_impact=0.714938 false_positive_rate_difference=-0.108919
	Los datos de esta intervención están distribuidos mediante ROS con: S=M C=1:13285, S=M C=0:12753, S=F C=1:906, S=F C=0:1438. Y fue	Sin intervención	f1_score=0.493317 recall=0.582079 precision=0.428044 disparate_impact=0.573801 false_positive_rate_difference=-0.136467

	utilizado <i>cross-validation</i> a 5 folds.		
--	--	--	--

5. Evaluación

Una vez establecido el modelo que se utilizará se procede nuevamente a realizar la evaluación de las métricas definidas, para revisar varios aspectos para comprender la calidad y el rendimiento del modelo (Cabrera, y otros, 2023).

5.1 Evaluación de los resultados

Es importante analizar los casos en los que el modelo ha cometido errores. Esto puede ayudar a identificar patrones o características problemáticas en los datos y proporcionar información para mejorar el modelo.

Tabla 12. Análisis de resultados

Métrica	Descripción
F1-score (F1). Elegida porque resume en un solo valor el equilibrio entre identificar verdaderos reincidentes y evitar etiquetar como reincidentes a quienes no lo son	En la Tabla 10, el mejor F1 bruto es de GaussianNB (0,473), seguido de QDA (0,451); los ensambles (XGB, ExtraTrees) quedan más abajo (0,371–0,346) y la red neuronal es la más débil (0,227). Con intervención (Tabla 11), XGB+ROS+HP sube a 0,517, superando en +0,044 absoluto a GaussianNB y en +0,146 a XGB sin intervención, mostrando que el balanceo y la optimización sí mejoran el equilibrio global.
Recall (TPR o sensibilidad). Elegido porque, desde una perspectiva de seguridad y prevención, interesa no omitir a quienes probablemente reincidirán.	En la Tabla 10, GaussianNB logra recall=0,730 (el más alto), $\Delta\text{FPR}=-0,590$, una señal de que “alto recall” viene acompañado de inequidades. Tras las intervenciones (Tabla 11), DecisionTree alcanza 0,690 y XGB+ROS/RUS+HP ronda 0,652–0,654; además, DecisionTree mantiene $\Delta\text{FPR}=-0,035$ y $\text{DI}\approx 0,913$, mucho más sano que NB. Si se prioriza no perder reincidentes, DecisionTree y XGB con balanceo ofrecen recall alto sin los extremos de inequidad de NB. Adaptabilidad. El recall cayó de 0,730 (NB) a $\sim 0,65-0,69$ (XGB/DT con mejor equidad). Esto sugiere que el trade-off de mantener recall alto con mayor equidad requiere intervenciones que los logren equilibrar.
<i>Precision</i> (PPV). Elegida porque centra el costo de intervenir sobre quien no reincidiría; en contextos de justicia y reinserción, minimizar falsos positivos para no imponer restricciones injustificadas.	En la Tabla 10, la red neuronal marca la <i>precision</i> más alta (0,618), pero con recall=0,139 y $\text{F1}=0,227$ y $\text{DI}=0,033$; es decir, “acierta” cuando marca positivo, pero casi no marca positivos y es inequitativa. XGB muestra 0,555 de <i>precision</i> pero con recall=0,279 y $\text{F1}=0,371$. Con intervención (Tabla 11), XGB+ROS+HP queda en 0,428 de <i>precision</i> pero eleva recall a 0,652 y F1 a 0,517; es un

	mejor compromiso que la red neuronal. Si se sube demasiado el umbral para maximizar precisión, se producen caídas de recall/F1 y señales de inequidad; por eso, XGB balanceado es más estable para decisiones. La precisión varía al re-balancear (ROS/RUS) bajando levemente pero el rendimiento global sube.
false_positive_rate_difference (Δ FPR o FPRD): diferencia de tasas de falsos positivos entre grupos (protegido – privilegiado). Elegida porque cuantifica trato desigual en errores de “falso positivo”, particularmente sensible en decisiones que pueden agravar condiciones para personas no reincidentes.	En la Tabla 10, GaussianNB tiene Δ FPR=-0,590 y DI=0,000: el grupo protegido recibe casi ningún positivo; por eso su FPR “parece” bajo allí, pero es una paridad espuria por infra-selección. DecisionTree muestra Δ FPR=-0,021 (cercano a 0) y DI=0,911, el perfil más equilibrado. Los ensambles quedan intermedios (p. ej., XGB Δ FPR=-0,062 y DI=0,429). En la Tabla 11, XGB+ROS+HP mejora F1 y recall, pero su Δ FPR=-0,165 aún indica asimetría; DecisionTree mantiene Δ FPR=-0,035 con DI≈0,913. Implicaciones en la salida. Con NB, el sistema omite positivos en el grupo protegido; con XGB+ROS+HP, mejora el desempeño, pero aún hay sesgo de FP (mayor carga de FP en un grupo); con DT, las decisiones se reparten con mucha más simetría de error.

6. Intervenciones de Equidad

En esta sección se reportan los resultados que presentan un mejor rendimiento. El análisis comienza con los modelos que obtuvieron las métricas de rendimiento más altas, junto con valores cercanos a uno en el tratamiento dispar y cercanos a cero en el valor absoluto de la diferencia entre las tasas de falsos positivos. Los resultados que se muestran corresponden a los cinco mejores modelos, ordenados primero con mayor prioridad por rendimiento y en segundo lugar por equidad.

6.1 Preprocesamiento (Comprensión y preparación de los datos)

Consiste en ajustar los datos antes de iniciar el proceso de entrenamiento. Estos métodos pueden resultar atractivos cuando se contempla la publicación de un conjunto de datos, para garantizar resultados justos a partir de modelos entrenados con ellos (Nielsen, 2020).

En la tabla 13, se muestra como las cuatro variantes de XGBClassifier (XGB) con optimización de hiper-parámetros y balanceo muestran un desempeño semejante ($F1 \approx 0,511-0,515$; $\text{recall} \approx 0,652-0,658$; $\text{precisión} \approx 0,418-0,425$), pero cada combinación ajusta de forma distinta el perfil de equidad: suprimir el atributo sensible con ROS entrega el mejor F1 (0,5147) con DI=0,983 y FPRD=0,0115, es decir, rendimiento alto con paridad de selección equitativa y brecha de falsos positivos mínima; al cambiar a asignación de pesos a cada ejemplo según su grupo sensible y su etiqueta con ROS se mantiene el desempeño ($F1=0,5144$; $\text{recall}=0,6545$) y se impulsa ligeramente la selección del grupo

protegido (DI=1,0665), asumiendo una asimetría de FP (FPRD=0,0489); con asignación de pesos a cada ejemplo según su grupo sensible y su etiqueta y RUS se preserva la paridad semejante (DI≈1,010) con FPRD=0,0309 y F1=0,5111, mientras que suprimir el atributo sensible con RUS logra la mejor simetría de error (FPRD=0,0014) a costa de una leve infra-selección del protegido (DI=0,947) y F1=0,5109; en contraste, DecisionTreeClassifier prioriza la captura de casos (recall=0,6925) pero sacrifica precisión (0,395) y F1 (0,503), manteniendo un perfil de equidad razonable (DI=0,964; FPRD=-0,012). Si se busca un máximo rendimiento con equidad estable, suprimir el atributo sensible con ROS es la opción más redonda; si la institución desea corrección moderada a favor del protegido, REWEIGHTER con ROS ofrece ese sesgo positivo controlando el costo en FP; si la prioridad es minimizar asimetrías de error, UNAWARENESS con RUS es la más simétrica; y si la meta es maximizar detección por encima de la carga operativa, el árbol de decisión es el que más recupera positivos, asumiendo más falsos positivos.

Tabla 13. Resultados preprocesamiento

Clasificador	Intervención	F1	Recall	Precisio n	DI	FPRD
XGBClassifier ¹	UNAWARENESS y HYPERPARAMETER y ROS	0.51472 3	0.65161 3	0.42536 3	0.98302 7	0.01153 3
	REWEIGHTER y HYPERPARAMETER y ROS	0.51436 6	0.65448 0	0.42366 6	1.06649 5	0.04890 2
	REWEIGHTER y HYPERPARAMETER y RUS	0.51113 6	0.65806 5	0.41784 3	1.00999 4	0.03092 8
	UNAWARENESS y HYPERPARAMETER y RUS	0.51085 1	0.65806 5	0.41746 2	0.94715 7	0.00140 7
DecisionTreeClassi fier	UNAWARENESS y HYPERPARAMETER (max_depth=8, min_samples_split=0 .03) y RUS	0.50312 5	0.69247 3	0.39509 2	0.96379 4	- 0.01224 8

6.2 Procesamiento (Modelado)

En este caso los datos originales no se ajustan, sino que se optimiza un modelo para que además de ser preciso sea justo. Generalmente, se aplica cuando los conjuntos de datos son tan grandes que las intervenciones de preprocesamiento no son viables debido a los recursos computacionales (Nielsen, 2020).

Las intervenciones de equidad que se muestran en la tabla 14, corresponden a Fairness for Free, que introduce durante el entrenamiento una restricción de equidad en “equidad

¹ Los hiper-parámetros se mostraron en la tabla 11.

diferencial” que es calculada a partir de las distribuciones estimadas del atributo protegido en los datos. FAIR_PCA, realiza la reducción de dimensionalidad por selección aprendida: entrena una máscara que pondera cada atributo y, tras establecer umbrales, conserva solo los más informativos. La máscara se optimiza en un esquema adversario que equilibra utilidad predictiva con una penalización de paridad demográfica para desalentar la dependencia de rasgos sensibles.

Como se muestra en la tabla 14, la red neuronal, FAIR_FOR_FREE con ROS es la combinación más equilibrada: logra el mejor F1 (0,5121) con recall 0,6459, precisión 0,4242 y casi nula asimetría de error (FPRD=0,00025). FAIR_FOR_FREE con RUS mantiene F1 similar (0,5087) y FPRD casi cero (0,0025), acercando la paridad de selección (DI=0,9393). Al añadir FAIR_PCA sube el recall (hasta 0,6660 con RUS) pero cae la precisión (0,3807) y aumentan las brechas (FPRD=0,0677–0,1052; DI=1,078–1,161), es decir, más cobertura del protegido a costa de más falsos positivos. Adversarial Debiasing con RUS elevan la precisión (0,4691) con menor recall (0,5004) y brecha moderada (FPRD=0,0616; DI=1,0709).

Tabla 14. Resultados procesamiento

Clasificador	Intervención	F1	Recall	Precisión	DI	FPRD
Red Neuronal	FAIR_FOR_FREE y ROS	0.512077	0.645878	0.424200	0.897086	0.000251
	FAIR_FOR_FREE y RUS	0.508677	0.640860	0.421698	0.939313	0.002525
	FAIR_FOR_FREE y RUS FAIR_PCA	0.484485	0.665950	0.380738	1.078266	0.067662
	ADVERSARIAL_DEBIASING y RUS	0.484218	0.500358	0.469086	1.070897	0.061589
	FAIR_FOR_FREE y ROS FAIR_PCA	0.481977	0.594265	0.405379	1.161274	0.105180

6.3 Post- procesamiento (Evaluación)

Estos métodos están encaminados a buscar la generación de resultados más justos, con una serie de métricas que se encargan de establecer la injusticia que produce el modelo al ser generados con datos que no han sido procesados pensando en la equidad. Estas medidas generalmente se basan en la comparación entre grupos en lugar de individuos (Nielsen, 2020).

En la tabla 15, se muestran que los resultados tienen intervenciones relacionadas con combinaciones de balanceo como SMOTE con S=M y C=1 (13045), S=M y C=0 (12753), S=F y C=1 (1146) y S=F y C=0 (1438). También se tienen balanceo con equidad con BAL_GAN_FAIR que implementa una GAN que incorpora una pérdida de equidad (puntuación de discriminación) para reducir las diferencias de tasas entre grupos protegidos y no protegidos antes de entrenar el modelo. Otra intervención, pero en posprocesamiento es *CounterfactualAnalyzer*, que realiza un análisis de posprocesamiento basado en contrafactuales que muestra cuantos cambios se debe hacer en los atributos para cambiar la salida del modelo.

En los resultados de la tabla 15, una combinación de QDA con CounterfactualAnalyzer con ROS y optimización de hiper-parámetros ofrece el mejor desempeño ($F1=0,805$; $\text{recall}=0,752$; $\text{precisión}=0,866$), seguido de QDA con BAL_GAN_FAIR optimización de hiper-parámetros ($F1=0,773$) y QDA con SMOTE y optimización de hiper-parámetros ($F1=0,768$), pero en los tres casos la paridad de selección es muy baja ($DI\approx 0,30-0,34$), y la diferencia de falsos positivos es casi nula ($FPRD\approx 0$). La combinación de XGB con BAL_GAN_FAIR con optimización de hiper-parámetros y CounterfactualAnalyzer rinde algo menos ($F1=0,745$; $\text{recall}=0,675$; $\text{precisión}=0,832$) y disminuye equidad ($DI=0,157$; $FPRD=-0,141$).

Tabla 15. Resultados posprocesamiento

Clasificador	Intervención	F1	Recall	Precisión	DI	FPRD
QuadraticDiscriminantAnalysis	ROS_HYPERPARAMETER (reg_param=0.5) y CounterfactualAnalyzer	0.80517	0.752461	0.865696	0.306481	-0.000789
	BAL_GAN_FAIR_HYPERPARAMETER (reg_param=0.5) y CounterfactualAnalyzer	0.773333	0.693390	0.874113	0.295264	0.000797
	SMOTE e HYPERPARAMETER (reg_param=0.5) y CounterfactualAnalyzer	0.767939	0.707454	0.839733	0.335229	-0.012693
XGBClassifier	BAL_GAN_FAIR_HYPERPARAMETER y CounterfactualAnalyzer	0.745342	0.675105	0.831889	0.156510	-0.141155

6.4 Reporte final

Al finalizar el entrenamiento, se obtiene un conjunto de modelos construidos mediante intervenciones de equidad que cumplen con los criterios de la frontera de Pareto. Las métricas asociadas a estos modelos son analizadas para identificar las intervenciones más prometedoras, las cuales se considerarán en la recomendación final sobre las fases más apropiadas del proceso de machine learning para implementar dichas intervenciones. En este caso los resultados que se muestran son aquellos que no empeoran frente a la línea base y que adicionalmente la superan en más de una métrica.

En la tabla 16, se puede observar como las intervenciones muestran avances con relación a la línea base. Solamente las intervenciones sobre las salidas del modelo como CERFI FAI, en donde mediante un algoritmo evolutivo que cambia cada instancia de datos hasta

encontrar aquellos contraejemplos cercanos a al ejemplo inicial pero que cambian la predicción, esto permitió mejorar los resultados con relación a la línea base.

Tabla 16. Resumen resultados


Clasificador	Intervención	Métricas rendimiento	Métricas equidad	Observación
QuadraticDiscriminant Analysis	HYPERPARAMETER y CERTI FAI	Recall=1 F1=0.7114 Precision=0.5555	FPRD=0 DI=1	Paridad ideal y alto recall. Se logra una compensación entre rendimiento y equidad al limitar las salidas del modelo
	FOS e HYPERPARAMETER y CERTI FAI	Recall=1 F1=0.7114 Precision=0.5555	FPRD=0 DI=1	
	REWEIGHTER e HYPERPARAMETER y CERTI FAI	Recall=1 F1=0.7114 Precision=0.5555	FPRD=0 DI=1	

6.5 Proceso de revisión

Luego de tener resultados de evaluación del modelo se pueden establecer un conjunto de acciones para comprender cómo se toman las decisiones. Los valores que se exponen en las figuras 5 y 6, son la media de la importancia que cada una de las características tuvo en las decisiones de los modelos que lograron el mejor equilibrio entre rendimiento y equidad. Dichos valores son aquellos que se obtuvieron en la resolución de un procedimiento que combinaba la reevaluación de los datos (imitando un proceso de generación de resultados) y la explicación de las predicciones de forma que cada atributo quedaba vinculado a un peso proporcional a su contribución a la generación de resultados. En estas figuras ayudan a decidir cuál de los clasificadores le proporciona menor importancia al atributo sensible.


La figura 5, muestra la importancia que se le dio al atributo sexo por los diferentes clasificadores que fueron utilizados para determinar cuáles de ellos a pesar tener una adecuada compensación entre rendimiento y equidad, también le dan una importancia menor al atributo sensible. Como se puede observar como el clasificador QuadraticDiscriminantAnalysis (siguiendo los resultados de la tabla 16), en combinación con diferentes intervenciones disminuye la importancia del atributo ENC_GENERO en la clasificación.

Figura 5. Importancia por clasificador atributo sexo



La figura 6, muestra las importancias absolutas ($|SHAP|$) de cada atributo por clasificador, ordenando los modelos según la contribución de sexo. Se observa que QuadraticDiscriminantAnalysis además de lograr una compensación, también depende menos del atributo sensible y presenta un perfil de importancias homogéneo, lo que sugiere menor sensibilidad a atributos individuales. En conjunto con los resultados previos de compensación rendimiento-equidad, este hallazgo respalda a dicho modelo como la alternativa con mejor balance.

Figura 6. Importancia por clasificador todos los atributos



REFERENCIAS

- Cabrera, Á. A., Fu, E., Bertucci, D., Holstein, K., Talwalkar, A., Hong, J. I., & Perer, A. (2023). Zeno: An Interactive Framework for Behavioral Evaluation of Machine Learning. *CHI Conference on Human Factors in Computing Systems* (págs. 1-14). Hamburg: ACM.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step Data Mining Guide*. SPSS.
- Fahse, T., Huber, V., & van Giffen, B. (2021). Managing Bias in Machine Learning Projects. En F. Ahlemann, R. Schütte, & S. and Stieglitz, *Innovation Through Information Systems* (págs. 94--109). Cham: Springer International Publishing.
- Holland, S., Hosny, A., Newman, S., Joseph, J., & Chmielinski, K. (2018). The Dataset Nutrition Label: A Framework To Drive Higher Data Quality Standards. *arXiv*, 1-21.
- Martínez-Plumed, F., Contreras-Ochando, L., Ferri, C., Hernández-Orallo, J., Kull, M., Lachiche, N., . . . Flach, P. (2021). CRISP-DM twenty years later: from Data Mining processes to Data Science trajectories. *IEEE Transactions on knowledge and data engineering*, 3048-3061.
- Nielsen, A. (2020). *Practical Fairness Achieving Fair and Secure Data Models*. Sebastopol: O'Reilly.
- Piorkowski, D., Richards, J., & Hind, M. (2022). Evaluating a Methodology for Increasing AI Transparency: A Case Study. *arXiv*, 1-15.
- Saltz, J., & Hotz, N. (2020). Identifying the most Common Frameworks Data Science Teams Use to Structure and Coordinate their Projects. *IEEE International Conference on Big Data (Big Data)* (págs. 2038-2042). Virtual: IEEE.
- Verma, S., & Rubin, J. (2018). Fairness Definitions Explained. *International Conference on Software Engineering* (págs. 1-7). Gotemburgo: IEEE/ACM.